

Adaptação de Domínio Livre de Fonte em Reconhecimento de Ações em Vídeo Baseada em Protótipos Multicêntricos

Exame de Qualificação — Mestrado em Informática

Miguel Vanderlei de Oliveira

Orientadora: Prof.^a Dr.^a Eulanda Miranda dos Santos

Instituto de Computação — IComp

Programa de Pós-Graduação em Informática — PPGI · UFAM

Manaus, Julho de 2026

| Sumário

Introdução e Motivação

Fundamentos

Trabalhos Relacionados

Abordagem Proposta

Resultados Preliminares

Considerações Parciais e Próximos Passos

01


Introdução e Motivação

Reconhecimento de Ações em Vídeo

- ▶ Tarefa fundamental da Visão Computacional
- ▶ Backbone padrão: **I3D** (Inflated 3D ConvNet)
- ▶ Excelente acurácia em UCF101, HMDB51 etc.

Problema — *Domain Shift*

Queda de desempenho ao mudar câmera, iluminação ou estilo de execução entre domínios.



Do UDA ao SFDA

UDA — Limitação

Exige dados da fonte durante a adaptação.
Inviável por **privacidade** e **armazenamento**.

SFDA — Solução

- (1) Pré-treinamento supervisionado na **fonte**
- (2) Adaptação no **alvo** sem dados da fonte

Estado da Arte — CleanAdapt (Dasgupta et al., 2025)

Trata adaptação como aprendizado com rótulos ruidosos. Seleciona fração τ de menor perda por classe (*small-loss trick*).

Limitação: trade-off **qualidade** $\times$ **cobertura** — penaliza classes minoritárias e cauda longa.

Objetivos

Objetivo Geral

Propor método de SFVDA com **protótipos multicêntricos** que supere a limitação de cobertura do CleanAdapt via **re-rotulagem geométrica** no espaço latente.

Objetivos Específicos:

1. Analisar o trade-off qualidade $\times$ cobertura do CleanAdapt
2. Propor agrupamento multicêntrico com re-amostragem balanceada
3. Implementar re-rotulagem por votação majoritária (KNN + K-Means)
4. Investigar estratégias *imbalance-aware* para cauda longa

02

Fundamentos

I Fundamentos — Visão Geral

1. Aprendizado Profundo / CNN

Entropia cruzada; SGD; overfitting

2. Arquitetura I3D

Inflated 3D ConvNet; pré-treino Kinetics

3. SFDA / SFVDA

Dois estágios; sem dados fonte

4. Pseudo-rótulos e Small-Loss

Efeito memorização (Arpit et al., 2017)

5. Estrutura Prof.-Aluno + EMA

$$\theta_T \leftarrow \alpha \theta_T + (1 - \alpha) \theta_S$$

6. K-Means e Protótipos

Agrupamento latente; vies de densidade

03

Trabalhos Relacionados


Posicionamento na Literatura

Método	Estratégia	Limitação
SHOT	Centroides + inf. mútua	Só imagens
ATCON	Consistência temporal	Rótulos globais inalterados
STHC	Banco de memória histórico	Sem topologia de classes
BMD	Agrupamento balanceado	Estima distrib. do alvo
DCPL	Matriz de transição ruído	Rótulos fixos
CleanAdapt	Small-loss + Prof.–Aluno	Trade-off qualidade × qtd.
Proposta	Protótipos multicêntricos	Agrupamento em cauda longa

04

Abordagem Proposta

Pipeline — Visão Geral



Os Quatro Passos da Re-rotulagem

1. **Subconjunto confiável** — Professor filtra fração τ de menor perda por classe $\Rightarrow \mathcal{D}_{cl}$.
Complemento: $\mathcal{D}_{un} = \mathcal{D}_t \setminus \mathcal{D}_{cl}$.
2. **Protótipos multicêntricos** — K-Means com K centroides sobre embeddings ℓ_2 -normalizados de $\mathcal{D}_{cl}^c$ para cada classe $c \in \mathcal{Y}$.
3. **Conjunto global** $\mathcal{P} = \bigcup_c \mathcal{P}_c$ — métrica **Mahalanobis** (selecionada via Optuna).
4. **Re-rotulagem por votação** $\hat{y}_i^* = \arg \max_c |\{\mu \in \mathcal{N}_k(x_i, \mathcal{P}) : \text{classe}(\mu) = c\}|$
Aluno treina sobre $\mathcal{D}_{cl} \cup \mathcal{D}_{un}^{\text{rel}}$.

Desacoplamento chave

τ controla apenas o *tamanho do âncora*, não a cobertura do treino.

Robustez — Distribuições de Cauda Longa

Problema

K-Means tem **viés de densidade**: classes majoritárias dominam os centroides.

Re-amostragem Balanceada

$n_{\min} = \min_c |\mathcal{D}_{cl}^c|$ instâncias por classe $\Rightarrow$ todas as classes contribuem igualmente para $\mathcal{P}$.

Direções Futuras

- ▶ Amostragem curricular — ISFDA
- ▶ Interseção de vizinhanças — Robust NN
- ▶ Classificador normalizado ℓ_2 — ICPR

05

Resultados Preliminares

Resultados — UCF101 $\leftrightarrow$ HMDB51

Método	UCF $\rightarrow$ HMDB (%)	HMDB $\rightarrow$ UCF (%)
CleanAdapt+TS (baseline)	87,78	96,67
Aumento linear de τ	87,50	96,50
ATCON [†]	79,70	85,30
MTRAN [‡]	92,20	95,30
Protótipos (proposta)	92,78	98,25

[†] Backbone TRN; [‡] Transformer multimodal

UCF $\rightarrow$ HMDB

+5,00 p.p. sobre baseline
(direção mais difícil; alvo desbalanceado)

HMDB $\rightarrow$ UCF

+1,58 p.p. sobre baseline
Competitivo com Transformers via I3D

Perguntas de Pesquisa

PP1 — Sensibilidade ao τ

- ▶ Proposta: τ regula âncora, não cobertura
- ▶ Melhor UCF $\rightarrow$ HMDB com $\tau = 0,2$
- ▶ Âncora pequeno + re-rotulagem = suficiente

PP2 — $K > 1$ vs $K = 1$

- ▶ $K > 1$ supera $K = 1$ em até +1,94 p.p. em $\mathcal{D}_{un}$
- ▶ Múltiplos centroides capturam sub-modos intra-classe

Epic-Kitchens

Limitação em distribuições de cauda longa

Resultado

Baseline supera proposta nos 6 cenários, com lacuna de até **16 p.p.**

Diagnóstico

Viés de densidade do K-Means e pseudo-rótulos iniciais ruidosos.

Direção

Estratégias *imbalance-aware* nos próximos passos.

06

Considerações Parciais e Próximos Passos

Contribuições e Cronograma

Contribuições:

- ▶ Re-rotulagem geométrica multicêntrica
- ▶ +5 p.p. sobre SOTA em UCF $\leftrightarrow$ HMDB
- ▶ Desacoplamento âncora/cobertura via τ
- ▶ **Artigo aceito no BRACIS 2026**

Próximos Passos:

1. Validar re-amostragem no Epic-Kitchens
2. Amostragem curricular (ISFDA)
3. Interseção de vizinhanças (Robust NN)
4. Comparação ampliada + redação final (2027)

Obrigado!

Apoio



Miguel Vanderlei de Oliveira

miguel.vanderlei@icomp.ufam.edu.br



UFAM